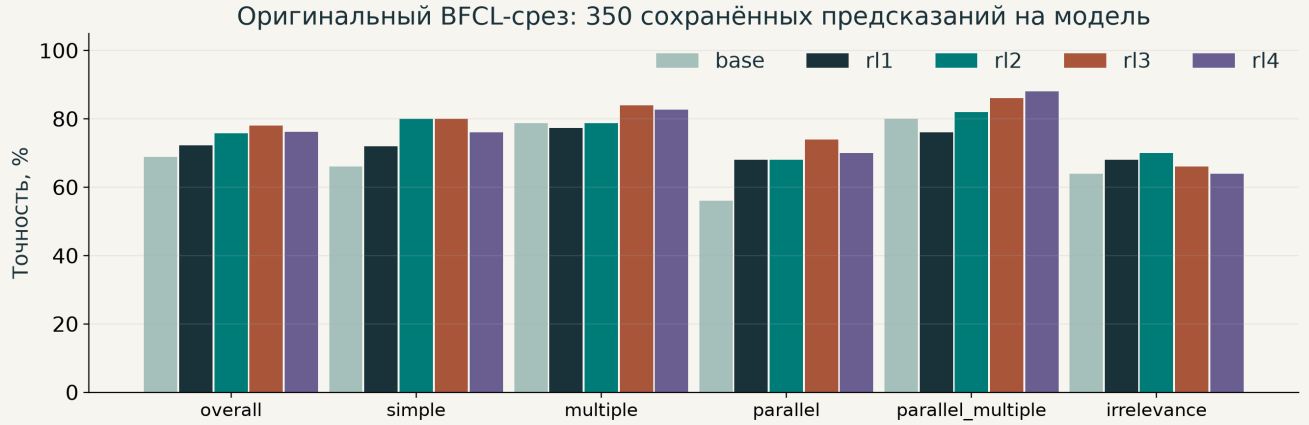
RL для вызова инструментов

Qwen3.5-2B · ToolACE · GRPO · домашнее задание 5

Лучший наблюдаемый BFCL среди четырёх конфигураций: rl3. BFCL macro score: 78.00%; исходная модель: 68.93%. Максимум по ToolACE validation среди конфигураций: rl4. Шаг каждой конфигурации выбран по validation, до дополнительных BFCL-замеров.



Модель	Overall	Simple	Multiple	Parallel	Parallel + multiple	Irrelevance
base	68.93%	66.00%	78.67%	56.00%	80.00%	64.00%
rl1	72.27%	72.00%	77.33%	68.00%	76.00%	68.00%
rl2	75.73%	80.00%	78.67%	68.00%	82.00%	70.00%
rl3	78.00%	80.00%	84.00%	74.00%	86.00%	66.00%
rl4	76.13%	76.00%	82.67%	70.00%	88.00%	64.00%

Pooled accuracy по 350 строкам: base=71.71%; rl1=73.71%; rl2=76.57%; rl3=79.71%; rl4=78.00%

Выбранная RL-модель выше baseline на 9.07 п.п. в этом запуске.

Основной score: среднее пяти групп; внутри multiple и irrelevance сначала усредняются исходные категории. Pooled accuracy по 350 строкам приведена отдельно. Все метрики сверены с metrics.json и SHA256 исходного bfcl.jsonl. BFCL не использовался для обучения и выбора checkpoint.

Данные и воспроизводимость

Обучение только RL на Team-ACE/ToolACE; дополнительного SFT нет. Reference calls передаются reward-функции и не добавляются к целевому prompt. История содержит только предыдущие сообщения. Native tokenizer формирует XML-вызовы; enable_thinking=False.

Данные	Измерение
Исходных диалогов	11300
Точных дубликатов	3
Решений с вызовом / без вызова	9424 / 2293
Исключения	Альтернативные схемы: 518; некорректные цепочки вызовов: 200; ответы после tool-result: 1335
Пересечение диалогов split	0

Split	Диалогов	Примеров	Call / no-call	Prompt p50 / p95 / max
train	1972	2048	1536 / 512	724 / 1464 / 2821
validation	125	128	96 / 32	710 / 1418 / 1960

Детерминированный split по хешу целого исходного диалога, seed 42; одинаковые строки дедуплицируются. Лимит prompt применяется после split; затем выборка с целевой долей no_call 25%. Альтернативные схемы и непарсируемые reference-вызовы исключены с явным учётом. Имена функций нормализованы с разрешением коллизий; AST literal_eval не выполняет код.

Dataset revision: 6bda777c88d21e5a204703c1ee45597a8fa4f734
Base revision: 15852e8c16360a2fea060d615a32b45270f8a8fc

Источник: https://huggingface.co/datasets/Team-ACE/ToolACE
Модель: https://huggingface.co/Qwen/Qwen3.5-2B
Метод: https://huggingface.co/docs/trl/grpo_trainer

Три контролируемых запуска и RL4



Run	Reward	Loss / scale	Шаг	Train, с	Eval, с
rl1	exact	grpo / group	80	1289.9	81.4
rl2	shaped	grpo / group	160	1900.3	83.0
rl3	shaped	dr_grpo / none	160	1054.9	80.0
rl4	shaped	dr_grpo / none	320	2548.4	74.5

Гипотеза rl1: строгая exact-награда повысит долю полностью правильных вызовов. Гипотеза rl2: частичный credit за имена и аргументы даст более плотный сигнал и улучшит exact accuracy. Гипотеза rl3: устранение нормализации по длине ответа и std reward уменьшит соответствующие смещения; проверяем совместное изменение, а не каждый фактор отдельно.

GRPO усредняет token-loss каждого ответа по его длине; Dr. GRPO использует фиксированный T_max из max_completion_length и здесь одновременно scale_rewards=none. Численное значение T_max берётся из фактического config ниже.

Фактическая конфигурация rl1: seed=42; max_steps=160; learning_rate=5e-05; per_device_train_batch_size=4; gradient_accumulation_steps=4; num_generations=4; max_completion_length=512; temperature=0.8; beta=0.02; epsilon=0.2; lora_rank=16

rl1: ToolACE validation - шаг 80: 77.34%; шаг 160: 75.00%; полные merged-веса экспортированы.

rl2: ToolACE validation - шаг 80: 62.50%; шаг 160: 68.75%; полные merged-веса экспортированы.

rl3: ToolACE validation - шаг 80: 71.09%; шаг 160: 71.88%; полные merged-веса экспортированы.

rl4: ToolACE validation - шаг 320: 78.91%; полные merged-веса экспортированы.

Обучение и оценка: avi-gn-fsk34, NVIDIA H100 80GB HBM3. torch 2.11.0; trl 1.16.0; transformers 5.9.0; peft 0.18.1; vllm 0.22.0. Native Torch CUDA 13.0; driver 590.48.01. Полный манифест: environment.json и environment.freeze.txt.

Время train включает validation и обучение, но не загрузку модели. JIT/кэши различались между запусками, поэтому это не сравнение чистой скорости алгоритмов. Eval измерен отдельным evaluator.

Гипотеза RL4: дополнительный бюджет обновлений улучшит перенос. Это длительный запуск того же Dr. GRPO из исходных весов: 320 шагов, один финальный validation/checkpoint, warmup 16 вместо 8. Это разведочный эксперимент; длительность и warmup здесь не разделены.

Кривые показывают только реальные записи без сглаживания. Значения exact и shaped reward, а также loss с разными нормировками не сравниваются как единая шкала качества. Один seed и один запуск на конфигурацию; доверительные интервалы не оценивались.

Ответы: reward, абляции и преимущество

1. Почему такая награда?

Exact: 1 только при совпадении мультимножества (имя, JSON аргументов). Shaped: R = 0.15 + 0.25 F1_имён + 0.30 F1_листьев_аргументов + 0.30 I_exact. Формула применяется только при корректном завершённом вызове и хотя бы одном совпавшем имени. Иначе 0. Для no_call награда 1 за непустой корректный ответ без вызова, иначе 0. Награда проверяет решение о вызове, имена и значения; мультимножества сохраняют повторные вызовы и не зависят от порядка. Частичная F1 листьев не закрепляет аргументы за отдельным повторным вызовом; корректность такого соответствия гарантирует только exact-компонента.

Расчётный пример	Exact	Shaped
Точный вызов	1.00	1.00
Верное имя, неверный city	0.00	0.40
Неверное имя	0.00	0.00
Пропущен обязательный вызов	0.00	0.00
Непустой ответ при no_call	1.00	1.00
Повреждённая разметка	0.00	0.00

Это расчётные примеры score_calls, не предсказания модели. В примере wrong city есть один лист аргумента: F1 имени=1, F1 листьев=0, exact=0, поэтому shaped=0.40.

2. Что дали абляции?

Для RL1-RL3 ниже сравнивается одинаковый шаг 160, чтобы не смешивать эффект настройки с выбором checkpoint. RL4 сравнивается на 320 шагах.

rl1 → rl2: замена exact на shaped; изменение BFCL macro -1.73 п.п. Это результат конкретных запусков; пары RL2/RL3 и RL3/RL4 меняют связанные параметры, поэтому их отдельные эффекты не идентифицируются.

rl2 → rl3: совместная замена loss на dr_grpo и отключение scale; изменение BFCL macro +2.27 п.п. Это результат конкретных запусков; пары RL2/RL3 и RL3/RL4 меняют связанные параметры, поэтому их отдельные эффекты не идентифицируются.

rl3 → rl4: бюджет 320 и warmup 16 вместо 160 и 8; изменение BFCL macro -1.87 п.п. Это результат конкретных запусков; пары RL2/RL3 и RL3/RL4 меняют связанные параметры, поэтому их отдельные эффекты не идентифицируются.

Наибольшее по модулю изменение: две нормировки Dr. GRPO, +2.27 п.п. Это сравнение при одном seed, а не оценка устойчивого среднего эффекта.

3. Совпадает ли рост reward с ростом BFCL?

Run	Шаг	ToolACE val	BFCL overall	Irrelevance	Reward, 20 шагов
rl1	80	77.34%	72.27%	68.00%	0.7156
rl1	160	75.00%	77.47%	66.00%	0.6406
rl2	80	62.50%	65.33%	8.00%	0.7225
rl2	160	68.75%	75.73%	70.00%	0.6894
rl3	80	71.09%	66.80%	40.00%	0.8156
rl3	160	71.88%	78.00%	66.00%	0.7612
rl4	320	78.91%	76.13%	64.00%	0.8432

rl1: Δreward=-0.0750; ΔBFCL=+5.20 п.п. Направления разошлись.

rl2: Δreward=-0.0331; ΔBFCL=+10.40 п.п. Направления разошлись.

rl3: Δreward=-0.0544; ΔBFCL=+11.20 п.п. Направления разошлись.

Для RL1-RL3 BFCL дополнительно измерен у обоих checkpoints после выбора по validation; у RL4 измерен только финальный шаг 320. Две точки показывают направление изменения, но не устойчивую корреляцию или причинность. Reward-окна содержат разные on-policy промпты и ответы; это описательное сравнение, не контроль на одном наборе. Все дополнительные predictions сохранены в step-N; BFCL не использовался для выбора шага.

4. Если в группе все reward одинаковы?

A_i = (r_i - mean(r)) / (std(r) + epsilon) = 0; при scale_rewards=none также r_i - mean(r) = 0.
Policy-gradient член от reward обнуляется. Полный градиент не обязан быть нулём: beta > 0 сохраняет KL к reference; возможен вклад KL и состояния оптимизатора. В самом начале, если policy совпадает с reference и накопленных состояний нет, этот вклад также может быть нулевым.

5. Ошибки на исходных 350 примерах

Run	Ошибок	False call	Missed call	Missing arg	Length
base	99	16	33	0	4
rl1	92	15	21	2	1
rl2	82	13	9	0	4
rl3	71	15	4	0	2
rl4	77	15	9	0	3

Таксономия ошибок основана на сохранённом check.valid и структурных признаках; argument_or_format не является отдельной семантической переоценкой. Ноль в таблице означает ноль наблюдавшихся случаев. Полные ответы, tool schema, ground truth и матрицы числа вызовов: error_analysis.json; все 350 строк: predictions.jsonl каждого run.

rl3 / irrelevance / irrelevance_178: false_call_irrelevance

Эталон не требует вызова. Модель всё же использовала доступный инструмент вместо ответа без вызова.

Запрос: Who is the most assist player in Premier League?

Ожидание: []

Ответ / распознанные вызовы: [{"sports_analysis.get_top_scorer": {"league": "Premier League", "season": "2023/2024"}}]

Checker: Вызов инструмента не требовался.

rl3 / simple / simple_241: missed_required_call

Модель ответила обычным текстом вместо вызова доступной функции. Даже содержательный текст не заменяет требуемый вызов.

Запрос: Who was the U.S. president during the Civil War?

Ожидание: [{"US_President_During_Event": {"event": ["Civil War"], "country": ["USA", ""]}}]

Ответ / распознанные вызовы: The U.S. president during the Civil War (1861–1865) was **Abraham Lincoln**.

He was elected in 1860 and took office in March 1861, leading the nation through the conflict that ended with the Emancipation Proclamation in 1863 and the Union's victory in 1865.

Checker: Ожидался вызов инструмента.

Примеры ошибок и проверка артефактов

rl1 / simple / simple_358: missed_required_argument

Выбрана нужная функция, но пропущен обязательный аргумент. Отсутствующее поле указано checker.

Запрос: Find a gluten-free cookie recipe that takes less than 30 minutes to prepare.

Ожидание: [{"recipe_search": {"diet": [["Gluten Free"], ["GF"], ["gluten free"]], "time_limit": [30], "dish": ["cookie"]}}]

Ответ / распознанные вызовы: [{"recipe_search": {"diet": ["Gluten Free"], "time_limit": 30}}]

Checker: ["Missing required parameter: 'dish'."]

rl3 / multiple / multiple_76: missed_required_call

Модель ответила обычным текстом вместо вызова доступной функции. Даже содержательный текст не заменяет требуемый вызов.

Запрос: I want to order a custom bronze sculpture of a horse. What material options are available?

Ожидание: [{"sculpture.create_custom": {"item": ["horse", "Horse"], "material": ["Bronze", "bronze"], "size": ["", 12]}}]

Ответ / распознанные вызовы: For a custom bronze sculpture of a horse, the available material options are:

* Bronze
* Marble
* Terracotta
* Wood
* Stone

Checker: Ожидался вызов инструмента.

rl3 / live_multiple / live_multiple_597-158-3: argument_or_format

Вызовы распознаны, но их аргументы или соответствие полного набора не проходят AST-проверку. Ниже видны полученные значения и ошибка checker.

Запрос: Search for a four-star hotel in Toronto, Canada? I would like to reserve one room.

Ожидание: [{"Hotels_4_SearchHotel": {"location": ["Toronto, Canada"], "star_rating": ["4"], "smoking_allowed": ["", false], "number_of_rooms": ["", "dontcare"]}}]

Ответ / распознанные вызовы: [{"Hotels_4_SearchHotel": {"location": "Toronto, Canada", "star_rating": "4", "number_of_rooms": 1}}]

Checker: ["Invalid value for parameter 'number_of_rooms': 1. Expected one of ['', 'dontcare']."]

rl3 / parallel / parallel_105: argument_or_format

Вызовы распознаны, но их аргументы или соответствие полного набора не проходят AST-проверку. Ниже видны полученные значения и ошибка checker.

Запрос: "Can you calculate the heat capacity at constant pressure of air for a science experiment I am conducting? I have a container with a volume of 2.5 m^3 and I am able to maintain the temperature at 300 Kelvin. I will be repeating the experiment at a higher temperature of 350 Kelvin and then at a lower volume of 1.5 m^3. I am using air for all these experiments. Can you provide the heat capacity for these three different conditions?"

Ожидание: [{"calc_heat_capacity": {"temp": [300], "volume": [2.5], "gas": ["air", ""]}}, {"calc_heat_capacity": {"temp": [350], "volume": [2.5], "gas": ["air", ""]}}, {"calc_heat_capacity": {"temp": [300], "volume": [1.5], "gas": ["air", ""]}}]

Ответ / распознанные вызовы: [{"calc_heat_capacity": {"temp": 300, "volume": 2.5, "gas": "air"}}, {"calc_heat_capacity": {"temp": 350, "volume": 2.5, "gas": "air"}}, {"calc_heat_capacity": {"temp": 350, "volume": 1.5, "gas": "air"}}]

Checker: ["Could not find a matching function among index [2] of model output for index 2 of possible answers.", {"Model Result Index 2": {"sub_error": ["Invalid value for parameter 'temp': 350. Expected one of [300]."], "sub_error_type": "value_error:others", "model_output_item": {"calc_heat_capacity": {"temp": 350, "volume": 1.5, "gas": "air"}}, "possible_answer_item": {"calc_heat_capacity": {"temp": [30 ... [обрезано; полный текст в JSON]

Полные merged-веса подтверждаются export_verification.json и хешами файлов; ненулевые LoRA B norms доказывают обновление adapter. Эти проверки не заменяют внешнюю оценку качества. Negative results и ошибки сохранены; SFT и обучение на BFCL не выполнялись.